

Chương 4: Xây dựng hệ thống

Chương này trình bày chi tiết quy trình cài đặt và thực nghiệm các thuật toán gợi ý phim đã giới thiệu ở Chương 2, bao gồm: Popularity Baseline, Collaborative Filtering (User-based và Item-based) và Matrix Factorization (SVD). Toàn bộ các mô hình được huấn luyện trên tập Train (80%), tinh chỉnh siêu tham số trên tập Validation (10%) và đánh giá hiệu năng cuối cùng trên tập Test (10%) thông qua các chỉ số RMSE, Precision@K và Recall@K.

4.1 Popularity Baseline

4.1.1 Nguyên lý triển khai

Popularity Baseline triển khai theo nguyên lý gợi ý không cá nhân hóa. Mô hình tính toán tổng số lượt đánh giá Popularity(i) mà mỗi bộ phim i nhận được trong tập huấn luyện (Train):

$$\text{Popularity}(i) = \sum [u \in U] I(r_{\{u,i\}} \neq \emptyset)$$

- U là tập hợp người dùng.
- $r_{\{u,i\}}$ là điểm đánh giá của người dùng u cho phim i.
- $I(r_{\{u,i\}} \neq \emptyset)$ nhận giá trị 1 nếu có tương tác trong tập Train, ngược lại nhận 0.

Sau đó, hệ thống sắp xếp các bộ phim theo số lượt tương tác giảm dần và chọn ra Top-K bộ phim phổ biến nhất để đề xuất chung cho tất cả người dùng.

4.1.2 Thuật toán và các bước thực hiện

1. Trích xuất dữ liệu: Duyệt qua tập dữ liệu Train, đếm số lượt xuất hiện của từng movieId.
2. Xếp hạng: Sắp xếp danh sách phim theo thứ tự giảm dần của lượt đánh giá.
3. Đề xuất: Với mỗi người dùng trong tập đánh giá (Validation/Test), loại bỏ các phim mà người dùng đó đã xem trong tập Train, sau đó chọn K phim có thứ tự phổ biến cao nhất còn lại để tạo danh sách Top-K.

4.2 Collaborative Filtering (Lọc cộng tác)

Hệ thống triển khai hai biến thể của Lọc cộng tác: User-based Collaborative Filtering và Item-based Collaborative Filtering.

4.2.1 User-based Collaborative Filtering

1. Xây dựng ma trận User-Item & Đo độ tương đồng:

- Xây dựng ma trận thưa User-Item R từ tập Train với kích thước $M \times N$ (610 người dùng $\times$ 9.724 phim).
- Tính ma trận độ tương đồng Cosine giữa hai người dùng u và v:

$$\text{sim}(u, v) = (\sum_i r_{\{u,i\}} \cdot r_{\{v,i\}}) / (\sqrt{\sum_i r_{\{u,i\}}^2} \cdot \sqrt{\sum_i r_{\{v,i\}}^2})$$

2. Tính điểm dự đoán và Tạo gợi ý:

Với một người dùng u và bộ phim i chưa đánh giá, mô hình xác định tập $N(u)$ gồm K_{neighbor} láng giềng gần nhất có độ tương đồng cao nhất với u . Điểm dự đoán $\hat{r}_{\{u,i\}}$ được tính bằng trung bình có trọng số:

$$\hat{r}_{\{u,i\}} = (\sum_{\{v \in N(u)\}} \text{sim}(u,v) \cdot r_{\{v,i\}}) / (\sum_{\{v \in N(u)\}} |\text{sim}(u,v)|)$$

4.2.2 Item-based Collaborative Filtering

1. Đánh giá độ tương đồng giữa các Phim:

Tính độ tương đồng Cosine giữa hai bộ phim i và j dựa trên các người dùng đã đánh giá cả hai bộ phim:

$$\text{sim}(i, j) = (\sum_u r_{\{u,i\}} \cdot r_{\{u,j\}}) / (\sqrt{ \sum_u r_{\{u,i\}}^2 } \cdot \sqrt{ \sum_u r_{\{u,j\}}^2 })$$

2. Tính điểm dự đoán:

Mức đánh giá dự đoán $\hat{r}_{\{u,i\}}$ của người dùng u cho phim i được suy ra từ tập I_u các bộ phim mà u đã từng đánh giá trong tập Train:

$$\hat{r}_{\{u,i\}} = (\sum_{\{j \in I_u\}} \text{sim}(i,j) \cdot r_{\{u,j\}}) / (\sum_{\{j \in I_u\}} |\text{sim}(i,j)|)$$

4.3 Matrix Factorization (SVD)

4.3.1 Kiến trúc mô hình Phân rã Ma trận

Mô hình SVD phân rã ma trận tương tác R thành hai ma trận yếu tố tiềm ẩn số chiều thấp:

- Ma trận người dùng P kích thước $M \times k$.
- Ma trận bộ phim Q kích thước $N \times k$.

Điểm đánh giá dự đoán $\hat{r}_{\{u,i\}}$ tích hợp thêm các thành phần chệch (bias):

$$\hat{r}_{\{u,i\}} = \mu + b_u + b_i + q_i^T \cdot p_u$$

- μ : Điểm đánh giá trung bình của toàn bộ tập huấn luyện.
- b_u : Độ lệch đánh giá riêng của người dùng u .
- b_i : Độ lệch đánh giá riêng của bộ phim i .
- p_u, q_i : Vector yếu tố tiềm ẩn k chiều của người dùng u và phim i .

4.3.2 Tối ưu hóa Hàm mất mát (Loss Function)

Mô hình học các tham số b_u, b_i, p_u, q_i bằng thuật toán Stochastic Gradient Descent (SGD) thông qua việc tối ưu hàm mất mát có thành phần chuẩn hóa (Regularization):

$$L = \sum_{\{u,i\} \in K} (r_{\{u,i\}} - \hat{r}_{\{u,i\}})^2 + \lambda \cdot (b_u^2 + b_i^2 + \|p_u\|^2 + \|q_i\|^2)$$

4.4 Tinh chỉnh tham số và Đánh giá thực nghiệm

4.4.1 Cấu hình tham số trên tập Validation

Sử dụng tập Validation (10,084 ratings) để lựa chọn cấu hình tối ưu cho các mô hình:

- Collaborative Filtering: Thử nghiệm số lượng láng giềng $K_{\text{neighbor}} \in \{10, 20, 30, 40, 50\}$. Kết quả cho thấy $K_{\text{neighbor}} = 20$ đạt chỉ số RMSE thấp nhất trên tập Validation.
- Matrix Factorization (SVD): Thử nghiệm lưới tham số (Grid Search):
 - - Số yếu tố tiềm ẩn ($n_{\text{factors}} k$): 20, 50, 100
 - - Tốc độ học (learning rate γ): 0.002, 0.005, 0.01
 - - Hệ số chuẩn hóa (λ): 0.02, 0.05, 0.1
 - - Số epoch: 20, 30, 50
- Cấu hình tối ưu được chọn: $k = 100$, $\gamma = 0.005$, $\lambda = 0.02$, Epochs = 30.

4.4.2 Kết quả thực nghiệm trên tập Test

Sau khi huấn luyện mô hình với tham số tối ưu, hệ thống tiến hành đánh giá trên tập Test (10,084 ratings) với ba chỉ số RMSE, Precision@10, và Recall@10.

Phương pháp (Model)	RMSE ↓	Precision@10 ↑	Recall@10 ↑
Popularity Baseline	1.0235	0.0521	0.0412
User-based CF	0.9682	0.0845	0.0718
Item-based CF	0.9421	0.0912	0.0785
Matrix Factorization (SVD)	0.8734	0.1345	0.1120

4.4.3 Phân tích và Nhận xét kết quả

1. Về khả năng dự đoán điểm (RMSE):

- Popularity Baseline có RMSE cao nhất (1.0235) do không có khả năng cá nhân hóa điểm đánh giá.
- Các phương pháp Collaborative Filtering cải thiện đáng kể độ chính xác nhờ khai thác sự tương đồng giữa các User/Item. Trong đó, Item-based CF đạt kết quả tốt hơn User-based CF do ma trận tương đồng giữa các phim ổn định hơn so with hành vi người dùng.
- Matrix Factorization (SVD) đạt chỉ số RMSE tốt nhất (0.8734), giảm hơn 14.6% sai số so với Popularity Baseline. SVD giải quyết hiệu quả độ thưa dữ liệu (98.3%) nhờ biểu diễn tương tác trong không gian yếu tố tiềm ẩn.

2. Về chất lượng danh sách đề xuất Top-K (Precision@10 & Recall@10):

- SVD vượt trội ở cả hai chỉ số Precision@10 (0.1345) và Recall@10 (0.1120). Điều này chứng tỏ mô hình không chỉ dự đoán đúng điểm số mà còn xếp hạng chính xác các bộ phim phù hợp lên đầu danh sách đề xuất cho người dùng.
- Popularity Baseline có kết quả Precision@K và Recall@K thấp nhất, cho thấy việc đề xuất cùng một danh sách các phim phổ biến cho mọi người dùng không mang lại trải nghiệm gợi ý chính xác.